



Universidad Simón Bolívar
Departamento de Computación y Tecnología de la Información
CO-6612, Introducción a las redes neuronales
Trimestre Enero-Marzo 2023
Tarea 6

Eros Cedeño 16-10216

Mapas Auto Organizativos

Mapas Auto Organizativos

Para esta tarea se solicitó la visualización de los 10 datos recibidos a lo largo del curso para comprender de mejor manera la distribución de los datos en el espacio y realizar observaciones con respecto a las redes neuronales anteriormente programadas.

Para la implementación se utilizó la librería `sklearn-som`, esta es una herramienta minimalista y simple que se encuentra disponible en los repositorios del manejador de paquetes de python. La documentación de esta librería se puede encontrar en el siguiente enlace:

<https://sklearn-som.readthedocs.io/en/latest/>

Además el código puede estudiarse sin problemas en el siguiente repositorio de github:


<https://github.com/rileypsmith/sklearn-som>

Se creó una SOM de tamaño 10x10 en 2 dimensiones para representar los datos. La cantidad de neuronas se mantuvo en 100 debido a las limitaciones del hardware sobre el cual se implementaron pruebas.

Luego se iteró sobre todos los archivos y se creó una matriz de datos que se usa para ajustar el SOM. El dispositivo retorna una lista de índices que hacen referencia a las neuronas de la SOM que se activaron al realizar el ajuste.

La figura inferior muestra la distribución de los datos y sus correspondientes neuronas activadas con el conjunto de entrenamiento. La SOM se caracteriza por estar basado en el


algoritmo de las k-medias pero siendo sin embargo estocástico. Por los resultados vistos se



puede concluir que los datos recibidos en los diferentes archivos se encuentran muy cercanos entre sí, por lo que los centros tienden a alinearse. Esto concuerda con los datos obtenidos en la MLP donde la clasificación de los datos presentaba tasa de acierto muy bajas, posiblemente por la cercanía y similitudes de los datos recibidos. Sin embargo se sugiere repetir el experimento pero por una mayor cantidad de épocas dado que se sabe que este algoritmo tiende a la convergencia usualmente luego de un número alto de épocas, esto no se pudo realizar por la baja capacidad de la computadora donde se realizaron las pruebas y se implementó la solución.

T-distributed stochastic neighbour embedding

Se utilizó otro método para visualizar los datos de alta dimensionalidad. Se utilizó el método conocido como el método de incrustación de vecinos estocásticos o T-SNE por sus siglas en inglés. Para aplicar este método se utilizó la clase TSNE de la librería sklearn. Y además se aprovecharon las bondades de la librería panda y matplotlib de python para hacer la gráfica correspondiente. El método T-SNE se caracteriza por su capacidad de



transformar espacios de alta dimensionalidad (512 en nuestro caso) a representaciones de baja dimensionalidad, 2D usualmente. Por lo que es una buena herramienta para comprobar la hipótesis obtenida con el SOM y caracterizar los datos

Una vez obtenida la gráfica de la representación de los datos por medio de la T-SNE la hipótesis anteriormente obtenida con el SOM cobra mayor fuerza. Como se observa en la figura anterior, los datos se encuentran aglomerados y sumamente acoplados entre sí lo que explica el por que anteriormente con los dispositivos basados en aprendizaje supervisado como la MPL o el SVM la clasificación resultaba ser una tarea complicada y poco certera. Ni hablar del Perceptrón o el Adaline que al no encontrar separabilidad lineal en estos datos su capacidad de generalización era en general muy mala. Por otro lado, considero que es posible que con tratamientos previos a los datos se pueda obtener mejores resultados y conglomerados mejor definidos que permitan predicciones correctas y adecuadas para los problemas de clasificación sobre este conjunto de datos.